

INFORME DE ASESORÍA ACADÉMICA

Neurociencia Computacional & Interfaces Cerebro-Computadora

Alumno
Álvaro Taipe
alvaro.taipe.c@uni.pe

Fecha
Abril 2026
Proyecto de Tesis 1

0. Evaluación Crítica del Punto de Partida

Este informe actúa como asesoría externa estricta y objetiva. El objetivo no es validarte, sino darte una hoja de ruta realista y exigente para que tu tesis tenga impacto académico real.

Antes de entrar al estado del arte, es fundamental que tengas clara una evaluación honesta de dónde estás parado. Tu trabajo previo en el pipeline VGG+VQGAN tiene valor como punto de partida, pero necesita ser reposicionado adecuadamente.

Lo que hiciste bien

- Identificaste un tema de investigación en la frontera del conocimiento (fMRI + reconstrucción de imágenes).
- Tomaste como base un paper de referencia sólido (Koide-Majima et al., 2024) con fundamento matemático claro (estimación Bayesiana).
- Reconociste los errores de tu modelo rudimentario (problemas en la reconstrucción del vector VGG con VQGAN), lo cual demuestra capacidad de autocrítica.
- Tienes hardware propio (RTX 3070) que, aunque limitado, permite experimentos reales.

Lo que debes corregir urgentemente

BRECHA CRÍTICA: Tu modelo actual usa VGG19 + VQGAN (pipeline del 2019-2022), mientras que el estado del arte 2023-2025 ya usa CLIP + Stable Diffusion XL / Versatile Diffusion + priors de difusión. Continuar con la arquitectura VGG+VQGAN como propuesta principal de tesis será rechazado por cualquier comité evaluador informado.

- La RTX 3070 tiene 8GB de VRAM. MindEye2 requiere una A100 (80GB). Esto no es un impedimento, pero debes planificar qué parte del modelo entrenarás localmente y qué usarás como referencia.
- La dispersión temática (Speech Decode, visual imagery, complejidad computacional, partición NP) es un riesgo grave. Una tesis debe tener un único hilo conductor y contribución definida.
- El trabajo autodidacta es válido, pero la tesis exige rigor metodológico: reproducción de baselines, métricas estandarizadas (Inception Score, SSIM, identificación pairwise) y comparación honesta.

1. Análisis de los Papers Proporcionados

1.1 Koide-Majima et al. (2024) — Neural Networks 170:349-363

Título: *Mental image reconstruction from human brain activity: Neural decoding of mental imagery via deep neural network-based Bayesian estimation*

Este es el paper que estás replicando y debe ser tu baseline principal. Aquí el análisis crítico:

Pipeline técnico

- Entrada: Señales fMRI mientras sujetos ven o imaginan imágenes naturales.
- Decodificador: Regresión lineal L2 para predecir activaciones de VGG19 (conv1-fc8) y CLIP (ViT-B/32) a partir de vóxeles cerebrales.
- Reconstrucción: Estimación Bayesiana con prior generativo VQGAN (ImageNet, $f=16$, 1024 tokens). Muestreo mediante SGLD (Stochastic Gradient Langevin Dynamics).
- Resultado clave: 90.7% identificación pairwise para imágenes vistas; 75.6% para imágenes imaginadas (vs. 50.4% baseline Shen 2019).

Fortalezas del paper

- Primera demostración exitosa de reconstrucción de imágenes mentales arbitrarias (no sólo formas básicas o rostros).
- La incorporación de CLIP como fuente de información semántica es el avance central sobre Shen et al. (2019).
- Dataset público disponible en Figshare (fMRI de 3 sujetos, 1200 imágenes entrenamiento, ImageNet 2011).

Limitaciones que tú puedes superar

El VQGAN como generador de imágenes es obsoleto (2021). Los modelos de difusión latente (Stable Diffusion, Versatile Diffusion) producen imágenes de calidad muy superior y son el estándar actual.

- Sólo 3 sujetos, muestra muy pequeña.
- El SGLD es lento (500 iteraciones por reconstrucción). Modelos de difusión modernos son más eficientes.
- No explora la región HVC (Higher Visual Cortex) de forma jerárquica para imaginaria.

1.2 MindEye / Scotti et al. (NeurIPS 2023) — arXiv:2305.18274

Título: *Reconstructing the Mind's Eye: fMRI-to-Image with Contrastive Learning and Diffusion Priors*

Este paper representa el salto cualitativo que buscas. Su arquitectura es el estado del arte hasta principios de 2024.

Pipeline técnico

- Pipeline de alto nivel (semántico): fMRI (15,000 vóxeles) → MLP residual (940M parámetros) → espacio CLIP ViT-L/14 → prior de difusión (estilo DALL-E 2) → Versatile Diffusion.
- Pipeline de bajo nivel (perceptual): fMRI → MLP → espacio latente VAE de Stable Diffusion → imágenes borrosas (estructura espacial).
- Combinación img2img: Las imágenes borrosas inician el proceso de difusión para preservar detalles de bajo nivel.
- Dataset: Natural Scenes Dataset (NSD), 24,980 muestras de entrenamiento por sujeto, 4 sujetos.
- Resultado clave: 93.2% recuperación top-1 (imagen exacta entre 982 candidatos), estado del arte en NSD.

Por qué MindEye supera a Koide-Majima en calidad visual

- Reemplaza VQGAN por Versatile Diffusion (modelos de difusión latente de alta calidad).
- El prior de difusión resuelve el 'modality gap': alinea los embeddings CLIP del cerebro con los embeddings CLIP de las imágenes.
- Contrastive learning (BiMixCo + SoftCLIP) produce embeddings cerebrales con información de grano fino.

2. Estado del Arte (2022–2026)

A continuación se presenta una revisión estricta de los trabajos más relevantes organizados por área. Solo se incluyen trabajos de los últimos 4 años. Esta es la literatura que DEBE aparecer en tu marco teórico y estar justificada en tu propuesta.

2.1 Reconstrucción fMRI → Imagen: Evolución cronológica

Paper / Año	Método Central	Métrica Clave
Koide-Majima et al. (2024)	VGG19 + CLIP + Bayes + VQGAN	75.6% imagery ID
Ozcelik & VanRullen (2023)Brain-Diffuser	VDVAE + CLIP + Versatile Diffusion	94.2% AlexNet-2
MindEye / Scotti et al. (NeurIPS 2023)	MLP 940M + Diffusion Prior + BiMixCo	93.2% retrieval top-1
MindEye2 / Scotti et al. (ICML 2024)	Multi-sujeto pretraining + SDXL unCLIP	~94% con 1h de datos
NeuroPictor (2025)	Pretraining multi-sujeto + Stable Diffusion XL	SOTA en low-level metrics
HI-DREAM (2025)	Pirámide cortical jerárquica V1/V2/V3/V4/LOC	Mejor preservación espacial
Brain-IT (2025)	Transformer fMRI + Deep Image Prior (DIP)	Bajo nivel mejorado

Brain-Diffuser — Ozcelik & VanRullen (2023)

Publicado en Scientific Reports. Usa VDVAE para reconstruir la estructura de bajo nivel, luego Versatile Diffusion condicionado en predicciones CLIP+texto (vía BLIP captioning). Redujo la distancia CLIP en 25.2% respecto al estado del arte anterior.

[Ver paper: nature.com/articles/s41598-023-42891-8](https://www.nature.com/articles/s41598-023-42891-8)

MindEye2 — Scotti et al. (ICML 2024)

El avance más importante de 2024. Pre-entrena en 7 sujetos del NSD y hace fine-tuning con solo 1 hora de datos de un nuevo sujeto mediante alineación funcional (proyección lineal a espacio latente compartido). Usa Stable Diffusion XL unCLIP con embeddings ViT-bigG/14 (1664 dimensiones). Alcanza rendimiento comparable al modelo completo (24,980 muestras) con menos del 5% de los datos.

[Ver paper: arxiv.org/abs/2403.11207](https://arxiv.org/abs/2403.11207)

[Código: github.com/MedARC-AI/MindEyeV2](https://github.com/MedARC-AI/MindEyeV2)

NSD-Imagery — Benchmark (CVPR 2025)

Dataset de referencia que extiende el NSD con imágenes mentales (imagery). Fundamental para evaluar modelos de reconstrucción de imaginaria. Confirma que arquitecturas de decodificación lineal simple generalizan mejor a imagery que arquitecturas complejas que sobreajustan a imágenes vistas.

Ver paper: arxiv.org/abs/2506.06898

2.2 Speech Decode desde fMRI (tu segundo enfoque)

Este es el área donde hay una contribución landmark de 2023 que es esencial que conozcas:

Tang et al. — Nature Neuroscience (2023) — EL PAPER MAS IMPORTANTE PARA TU ENFOQUE

"Semantic reconstruction of continuous language from non-invasive brain recordings". Primer decodificador no invasivo que reconstruye lenguaje continuo desde fMRI. El sistema genera secuencias de palabras inteligibles que recuperan el significado del habla percibida, habla imaginada e incluso videos silenciosos.

DATO CLAVE: El decoder usa GPT-1 como modelo de lenguaje y Brain Encoder (regresión lineal) para mapear fMRI → embeddings de texto. El sistema genera candidatos y selecciona el que mejor predice la actividad cerebral. Esto es exactamente el equivalente de Speech Decode no invasivo.

Ver paper: nature.com/articles/s41593-023-01304-9

Dataset Bimodal EEG-fMRI para Inner Speech — Scientific Data (2023)

Primer dataset público bimodal (EEG + fMRI no-simultáneo) para reconocimiento de habla interna. 4 sujetos, paradigma de imaginación de palabras en categorías social/numérica. Disponible en OpenNeuro (doi:10.18112/openneuro.ds004197.v1.0.2). Clasificación binaria: 71.72% combinando EEG+fMRI vs 56.17% solo fMRI.

Código: github.com/LTU-Machine-Learning/Inner_Speech_EEG_fMRI

Open-vocabulary Auditory Neural Decoding — arXiv 2024

Usa fMRI prompting de LLMs para decodificación auditiva con vocabulario abierto. Extiende el paradigma de Tang et al. a escenarios no restringidos.

Ver paper: arxiv.org/html/2405.07840v1

2.3 Datasets Open Source Fundamentales

Dataset	Descripción
Natural Scenes Dataset (NSD)	8 sujetos, 7T fMRI, ~9000 imágenes/sujeto, MS-COCO. Benchmark estándar. naturalscenesdataset.org

NSD-Imagery (CVPR 2025)	Extensión NSD para mental imagery. Pairs (visto, imaginado). Nuevo benchmark.
Deep Image Reconstruction (Figshare)	Dataset de Shen/Koide-Majima. 3 sujetos, 1200 imágenes. figshare.com (ver paper)
OpenNeuro Inner Speech	4 sujetos, EEG+fMRI, palabras imaginadas. openneuro.org ds004197
fMRI Language Dataset (BOLD5000)	4 sujetos, 5254 imágenes. Variedad temática mayor que NSD.

3. Propuesta de Título y Enfoque de Tesis

DECISIÓN CRÍTICA: Debes elegir UN solo hilo conductor. Los comités de tesis rechazan propuestas dispersas. A continuación se presentan dos opciones mutuamente excluyentes, con mi recomendación como asesor.

Opción A (RECOMENDADA): Reconstrucción de Imaginería Visual

TÍTULO PROPUESTO: "Reconstrucción de Imaginería Visual desde Señales fMRI mediante Modelos de Difusión Latente con Prior Semántico CLIP: Una Mejora al Marco Bayesiano de Koide-Majima"

Esta opción tiene las siguientes ventajas estratégicas:

1. Continuidad directa con tu trabajo previo (tienes el pipeline de Koide-Majima parcialmente implementado).
2. Contribución clara y medible: reemplazar VQGAN por Stable Diffusion / Versatile Diffusion y mejorar la precisión en imagery de 75.6% hacia 80%+.
3. Existen baselines públicos (NSD-Imagery, CVPR 2025) con los que puedes compararte directamente.
4. Tu RTX 3070 es suficiente para reproducir el pipeline de Koide-Majima y proponer mejoras modulares.
5. El dataset de Figshare (Koide-Majima) es pequeño y manejable para tu hardware.

Contribución técnica específica

Tu contribución debe ser concreta y verificable. Se propone la siguiente:

Sustituir el generador VQGAN en el marco de Koide-Majima por un modelo de difusión latente (Stable Diffusion 2.1 o Versatile Diffusion) con fine-tuning del prior para la tarea de imagery. Evaluar si el prior de difusión mejora la calidad semántica (CLIP score) y perceptual (SSIM, PixCorr) en la reconstrucción de imágenes imaginadas.

Opción B: Speech Decode desde fMRI

Título alternativo: "Decodificación Semántica de Habla Interna desde Registros fMRI No Invasivos mediante Modelos de Lenguaje de Gran Escala"

Esta opción es más ambiciosa y tiene mayor impacto social (comunicación para pacientes con ELA, locked-in syndrome). Sin embargo, tiene desventajas importantes para tu contexto:

- Requiere un dataset de fMRI + habla imaginada que actualmente es escaso y de pocos sujetos.

- El paradigma de Tang et al. (2023) ya es el estado del arte; diferenciarte es más difícil.
- La variabilidad inter-sujeto en procesamiento del lenguaje es mayor que en visión.
- La RTX 3070 puede ser insuficiente para fine-tuning de modelos de lenguaje grandes.

Enfoque Integrador (para el futuro, NO para la tesis de pregrado)

Tu visión a largo plazo (proyección del pensamiento visual en tiempo real) es correcta como dirección de investigación futura. Sin embargo, el camino correcto es:

6. Tesis 1: Reconstrucción offline de imagery visual (Opción A) — establece el precedente técnico.
7. Tesis 2 / Maestría: Decoding semántico multi-modal (visual + lenguaje) con alineación multi-sujeto.
8. Investigación doctoral / BCI en tiempo real: Procesamiento online de fMRI con inferencia rápida.

4. Herramientas, Frameworks y Datasets Recomendados

4.1 Stack Técnico Principal

Herramienta	Uso en tu Tesis
PyTorch 2.x + CUDA 12	Framework principal. Compatible con RTX 3070.
HuggingFace Diffusers	Stable Diffusion 2.1, Versatile Diffusion, SDXL. API unificada para modelos de difusión.
OpenCLIP (ViT-L/14, ViT-B/32)	Extractor de features semánticos. Igual al usado en Koide-Majima y MindEye.
nilearn + nibabel	Procesamiento de archivos fMRI (.nii, .nii.gz). Indispensable.
scikit-learn	Regresión L2, PCA, selección de vóxeles. Pipeline de decodificación.
Torchmetrics + pytorch-fid	Cálculo de Inception Score, FID, SSIM para evaluación.
Weights & Biases (wandb)	Seguimiento de experimentos. Gratuito para estudiantes.
TAMING-Transformers (VQGAN)	Para reproducir Koide-Majima. github.com/CompVis/taming-transformers

4.2 Consideraciones Críticas de Hardware (RTX 3070)

La RTX 3070 tiene 8GB de VRAM. Esto es INSUFICIENTE para entrenar MindEye o MindEye2 desde cero (requieren A100 80GB). PERO es SUFICIENTE para: (1) reproducir el pipeline de Koide-Majima con el dataset de Figshare (3 sujetos, modelos pequeños), (2) hacer inference/fine-tuning de Stable Diffusion 2.1 con bfloat16 y gradient checkpointing, (3) entrenar el decodificador lineal (regresión ridge) que es la parte computacionalmente ligera.

Estrategia para maximizar la RTX 3070

- Usar mixed precision (bfloat16 / fp16) en todos los modelos de difusión.
- Gradient checkpointing para reducir memoria durante backpropagation.
- Batch size 1-2 con gradient accumulation para simular batches grandes.
- xFormers para atención eficiente en memoria (compatible con PyTorch 2.x).
- LoRA (Low-Rank Adaptation) para fine-tuning eficiente del modelo de difusión.
- Usar los recursos remotos de la universidad para los experimentos grandes.

4.3 Procesamiento de Archivos fMRI Open Source

- nilearn (Python): Biblioteca principal para análisis de fMRI. Masking, GLM, conectividad.
- nibabel: Lectura/escritura de archivos NIfTI (.nii, .nii.gz), formato estándar fMRI.
- FreeSurfer: Segmentación cortical, mapeo a superficie. Para identificar ROIs visuales (V1-V4, HVC).
- fMRIPrep: Pipeline estandarizado de preprocesamiento. El dataset NSD ya viene preprocesado con fMRIPrep.
- OpenNeuro.org: Repositorio de datasets fMRI abiertos (BIDS format).

5. Complejidad Computacional: Relevancia para tu Investigación

Mencionaste los problemas de partición de 3 (3-Partition) y soluciones cercanas a NP. Aquí se clarifica cómo esto es relevante para tu tesis y dónde está la conexión real con neurociencia computacional.

5.1 ¿Dónde aparecen problemas NP en tu pipeline?

Selección óptima de vóxeles

El cerebro tiene ~50,000-200,000 vóxeles en la corteza visual. Seleccionar el subconjunto óptimo de k vóxeles para predecir activaciones DNN es formalmente NP-Hard (es una instancia del problema de selección de características óptima). La solución práctica usada en Koide-Majima es:

- PCA para reducir a los componentes que explican >99% de la varianza.
- Correlación de Pearson para filtrar vóxeles relevantes.
- Regresión L2 regularizada (solución aproximada eficiente).

Problema de partición de 3 en asignación de recursos

La conexión más directa: dado un conjunto de vóxeles y tres tareas (decodificar low-level, mid-level, high-level features), ¿cómo particionarlos óptimamente para maximizar la capacidad predictiva conjunta? Esto es una instancia del 3-Partition problem (NP-Hard).

HI-DREAM (2025) aborda esto con una solución jerárquica inspirada en la corteza visual: V1/V2 para bordes, V3/V4 para color/forma, LOC/FFA para semántica. Esta partición biológicamente motivada es una heurística eficaz para el problema NP.

Memoria dinámica y caché de embeddings

Para reconstrucción en tiempo real (tu visión a largo plazo), el problema de qué embeddings mantener en memoria activa vs. descargar a disco es una variante del problema de reemplazo de páginas (Belády's algorithm), que tiene soluciones óptimas offline pero es NP-Hard en el caso online sin información futura.

RECOMENDACIÓN: No incluyas la teoría de complejidad computacional como contribución central de tu tesis. Úsala como motivación para justificar las heurísticas que propones (partición jerárquica de ROIs, selección aproximada de vóxeles). Una sección de 1-2 páginas en el marco teórico es suficiente.

6. Hoja de Ruta para la Tesis

Esta hoja de ruta asume que eliges la Opción A (reconstrucción de imagery visual) y que tienes aproximadamente 6-8 meses para escribir la tesis.

Fase 1: Fundamentos y Reproducción (Meses 1-2)

9. Descargar y procesar el dataset de Figshare de Koide-Majima (fMRI + imágenes).
10. Reproducir el pipeline completo de Koide-Majima et al. (2024) con el código oficial de GitHub/Figshare.
11. Establecer métricas baseline: Inception Score, identificación pairwise (accuracy 75.6% objetivo inicial).
12. Leer y resumir: NSD paper, MindEye, Brain-Diffuser, Tang et al. 2023.

Fase 2: Propuesta de Mejora (Meses 3-4)

13. Sustituir VQGAN por Stable Diffusion 2.1 (fp16, con LoRA) como generador de imágenes.
14. Implementar un prior de difusión simplificado (similar al de MindEye pero más ligero para RTX 3070).
15. Experimentos de ablación: VQGAN vs SD2.1 en imágenes vistas.
16. Extender el experimento a imágenes imaginadas con el nuevo generador.

Fase 3: Evaluación y Escritura (Meses 5-6)

17. Evaluación cuantitativa completa: SSIM, PixCorr, Inception Score, identificación pairwise.
18. Comparación honesta con Koide-Majima (2024) como baseline principal.
19. Análisis de contribución de cada componente (ablation study).
20. Redacción del documento de tesis siguiendo el formato UNI.

Criterio de éxito mínimo para la tesis

Tu tesis es defendible si: (1) reproduces el baseline de Koide-Majima honestamente, (2) propones una modificación arquitectónica justificada teóricamente, (3) muestras resultados comparativos con métricas estandarizadas, aunque la mejora sea modesta (+2-5% en algún métrica). La honestidad metodológica vale más que resultados inflados.

7. Referencias Clave del Estado del Arte

Papers Fundamentales (OBLIGATORIO leer)

21. Koide-Majima N. et al. (2024). Mental image reconstruction from human brain activity. *Neural Networks* 170, 349-363. <https://doi.org/10.1016/j.neunet.2023.11.024>
22. Scotti P.S. et al. (NeurIPS 2023). Reconstructing the Mind's Eye: fMRI-to-Image with Contrastive Learning and Diffusion Priors. arXiv:2305.18274. <https://medarc.ai/mindeye/>
23. Scotti P.S. et al. (ICML 2024). MindEye2: Shared-Subject Models Enable fMRI-To-Image With 1 Hour of Data. arXiv:2403.11207. <https://github.com/MedARC-AI/MindEyeV2>
24. Ozcelik F. & VanRullen R. (2023). Natural scene reconstruction from fMRI signals using generative latent diffusion. *Scientific Reports*. <https://www.nature.com/articles/s41598-023-42891-8>
25. Tang J. et al. (2023). Semantic reconstruction of continuous language from non-invasive brain recordings. *Nature Neuroscience*. <https://www.nature.com/articles/s41593-023-01304-9>
26. Allen E.J. et al. (2022). A massive 7T fMRI dataset to bridge cognitive neuroscience and AI. *Nature Neuroscience*. [NSD Dataset] <https://naturalscenesdataset.org/>
27. Shen G. et al. (2019). Deep image reconstruction from human brain activity. *PLOS Computational Biology*. [Baseline histórico]

Papers Complementarios (Recomendado)

28. Chen Z. et al. (2025). NSD-Imagery: A benchmark for extending fMRI vision decoding to mental imagery. *CVPR 2025*. arXiv:2506.06898
29. Iamshchinina P. et al. (2023). Bimodal EEG-fMRI dataset for inner-speech recognition. *Scientific Data*. <https://www.nature.com/articles/s41597-023-02286-w>
30. HI-DREAM (2025). Brain-inspired hierarchical diffusion for visual reconstruction. arXiv:2511.11437
31. Open-vocabulary Auditory Neural Decoding using fMRI-prompted LLM (2024). arXiv:2405.07840
32. Visual Image Reconstruction from Brain Activity via Latent Representation. *Annual Review of Vision Science* 2024. <https://www.annualreviews.org/content/journals/10.1146/annurev-vision-110423-023616>

Recursos Open Source

33. NSD Dataset: <https://naturalscenesdataset.org/> (requiere solicitud de acceso)
34. Figshare Dataset (Koide-Majima): https://figshare.com/articles/dataset/Deep_Image_Reconstruction/7033577

- 35. OpenNeuro Inner Speech: <https://openneuro.org/datasets/ds004197>
- 36. MindEye GitHub: <https://github.com/MedARC-AI/MindEye1> y [MindEye2](https://github.com/MedARC-AI/MindEye2)
- 37. Brain-Diffuser GitHub: <https://github.com/ozcelikfu/brain-diffuser>

8. Resumen Ejecutivo del Asesor

Síntesis de los puntos críticos que debes internalizar antes de escribir tu propuesta de tesis.

Los 5 mensajes más importantes

- 38. ACTUALIZA TU STACK: VGG+VQGAN es 2019-2021. Tu tesis debe usar CLIP+Stable Diffusion como mínimo. El paper de MindEye2 (2024) es tu nueva referencia de estado del arte.
- 39. ELIGE UN TEMA: Visual imagery (Opción A) o Speech Decode (Opción B). No los combines en una sola tesis de pregrado. La amplitud mata la profundidad.
- 40. USA EL NSD o FIGSHARE: No inventes un dataset. Usa los públicos estandarizados para que tus resultados sean comparables con la literatura.
- 41. EVALÚA CON MÉTRICAS ESTÁNDAR: Inception Score, identificación pairwise, SSIM, PixCorr. Estas son las métricas usadas en todos los papers del campo. Sin ellas, tu trabajo no es comparable.
- 42. TU VISIÓN ES VÁLIDA PERO LEJANA: La proyección en tiempo real de pensamiento visual es una meta de investigación de 10-20 años. Tu tesis establece el PRIMER peldadón (reconstrucción offline de alta calidad). Eso ya es una contribución real y significativa.

Fortaleza actual	Brecha a cerrar
Conoces el paper de Koide-Majima en detalle	Actualizar a difusión latente (SD2.1/Versatile)
Tienes RTX 3070 funcional	Optimizar para 8GB VRAM (fp16, LoRA, xFormers)
Acceso a recursos universitarios remotos	Planificar qué experimentos correr localmente vs. remoto
Autodidacta con criterio propio	Disciplina metodológica (baselines, métricas, reproducibilidad)
Visión clara del objetivo de largo plazo	Scope reduction: enfocarse en contribución puntual y verificable

Este informe ha sido preparado como asesoría académica externa. Las recomendaciones son exigentes porque el objetivo es que tu tesis sea defendible y tenga impacto real en la comunidad científica de neurociencia computacional.

Informe generado con Claude (Anthropic) | Abril 2026 | Para uso académico exclusivo